Tarification automobile par GLM — BASEAUTO

Modélisation fréquence × coût et grille de prime pure

TCHIO CLAVERT

2026-10-16

Table des matières

1 Partie A — Analyse exploratoire **2**
1.1 Importation et visualisation des données . . . 2
1.2 Conversion des types de données . . . 3
1.3 Statistiques descriptives univariées . . . 3
1.3.1 Variables quantitatives . . . 3
1.3.2 Variables qualitatives . . . 5
1.4 Regroupements de modalités . . . 6
1.4.1 (a) CSP → 3 catégories . . . 6
1.4.2 (b) CLA → Eco / Inter / Cher . . . 7
1.4.3 (c) VIT → Lent / VitMoy / Rapide . . . 7
1.4.4 (d) CAR → Luxe / Commun / Familial . . . 8
1.5 Statistiques descriptives bivariées . . . 9
1.6 À quoi servent les analyses préliminaires ? . . . 11

2 Partie B — Préparation à la modélisation **12**
2.1 Profil de référence . . . 12
2.2 Séparation sinistres attritionnels / graves . . . 12
2.3 Base de construction du tarif . . . 14
2.4 Échantillons apprentissage / test . . . 14
2.5 Tests d'adéquation de la charge . . . 14

3 Partie C — Modélisation GLM **18**
3.1 GLM Fréquence — Loi Binomiale / Lien logit . . . 18
3.2 GLM Coût — Loi Gamma / Lien log . . . 22
3.3 Prise en compte des sinistres graves . . . 26
3.4 Grille de tarif . . . 26

4 Synthèse **29**
4.1 Limites et pistes . . . 29

---

1 Partie A — Analyse exploratoire

1.1 Importation et visualisation des données

```
df <- read.csv("BASEAUTO.csv", sep = ";", dec = ".", stringsAsFactors = FALSE)
cat("Dimensions :", nrow(df), "lignes x", ncol(df), "colonnes\n")
```

```
Dimensions : 10496 lignes x 17 colonnes
```

```
head(df, 6) |>
  kbl_out(caption = "Aperçu des 6 premières observations")
```

Table 1: Aperçu des 6 premières observations

PERMIS	ACV	SEX	STATUT	CSP	USAGE	AGECOND	K8000	RM	CAR	CLA	ALI	ENE	VIT	SEGM	GARAGE	CHARGE
245	10	F	C	50	2	40	N	64	BER	A	CAR	ES	130-140	A	3	0
348	10	F	A	50	1	63	N	50	BER	A	CAR	ES	001-130	0	3	0
16	10	F	C	26	2	20	N	95	BER	A	CAR	ES	001-130	0	3	0
291	10	F	A	50	1	56	N	50	BER	A	CAR	ES	001-130	0	3	0
123	10	F	A	50	1	29	N	95	BER	A	CAR	ES	140-150	B	3	0
295	10	F	A	37	1	43	O	50	BER	A	CAR	ES	001-130	A	3	0

```
str(df)
```

```
'data.frame':   10496 obs. of  17 variables:
 $ PERMIS : int  245 348 16 291 123 295 24 181 157 338 ...
 $ ACV    : int  10 10 10 10 10 10 10 9 10 10 ...
 $ SEX    : chr  "F" "F" "F" "F" ...
 $ STATUT : chr  "C" "A" "C" "A" ...
 $ CSP    : int  50 50 26 50 50 37 50 50 55 1 ...
 $ USAGE  : int  2 1 2 1 1 1 2 3 1 2 ...
 $ AGECOND: int  40 63 20 56 29 43 21 35 31 48 ...
 $ K8000  : chr  "N" "N" "N" "N" ...
 $ RM     : int  64 50 95 50 95 50 90 50 72 50 ...
 $ CAR    : chr  "BER" "BER" "BER" "BER" ...
 $ CLA    : chr  "A" "A" "A" "A" ...
 $ ALI    : chr  "CAR" "CAR" "CAR" "CAR" ...
 $ ENE    : chr  "ES" "ES" "ES" "ES" ...
 $ VIT    : chr  "130-140" "001-130" "001-130" "001-130" ...
 $ SEGM   : chr  "A" "0" "0" "0" ...
 $ GARAGE : int  3 3 3 3 3 3 3 3 3 2 ...
 $ CHARGE : int  0 0 0 0 0 0 0 0 0 179 ...
```

Interprétation : La base BASEAUTO contient **10496 polices** et **17 variables** : caractéristiques du conducteur (âge, sexe, statut, CSP, ancienneté du permis), du véhicule (type, classe SRA, énergie, vitesse, segment) et la variable cible **CHARGE** (montant annuel de remboursement en euros). Le taux de sinistralité est de **13.3%**.

1.2 Conversion des types de données

```
vars_quali <- c("SEX","STATUT","K8000","CAR","CLA","ALI","ENE","VIT","SEGM","USAGE","GARAGE")
for (v in vars_quali) df[[v]] <- as.factor(df[[v]])

# Tableau récapitulatif
data.frame(
  Variable  = vars_quali,
  Modalites = sapply(vars_quali, function(v) nlevels(df[[v]]))
) |> kbl_out(caption = "Nombre de modalités par variable qualitative")
```

Table 2: Nombre de modalités par variable qualitative

	Variable	Modalites
SEX	SEX	2
STATUT	STATUT	2
K8000	K8000	2
CAR	CAR	9
CLA	CLA	26
ALI	ALI	5
ENE	ENE	3
VIT	VIT	10
SEGM	SEGM	6
USAGE	USAGE	4
GARAGE	GARAGE	3

1.3 Statistiques descriptives univariées

1.3.1 Variables quantitatives

```
vars_quanti <- c("PERMIS","ACV","AGECOND","RM","CHARGE")

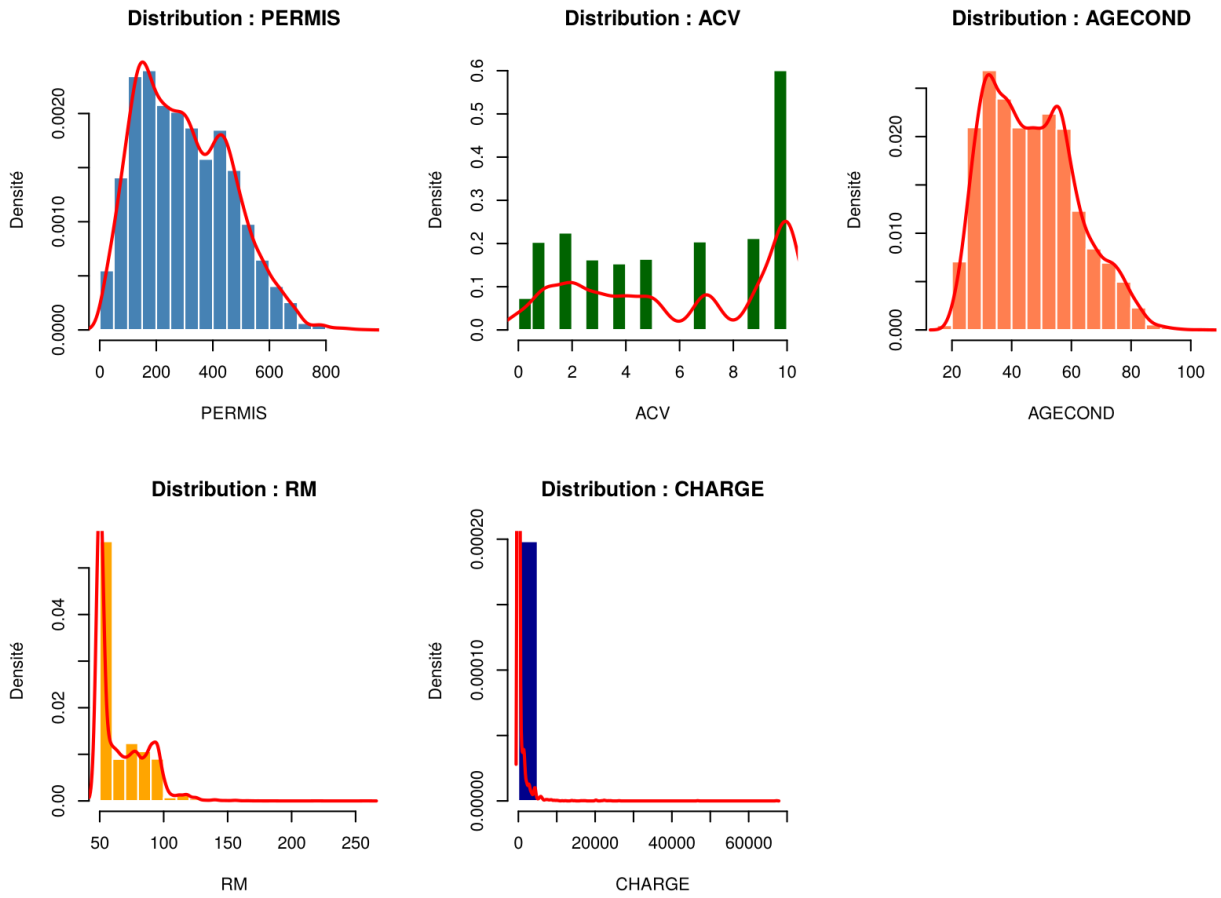
do.call(rbind, lapply(vars_quanti, function(v) {
  x <- df[[v]]
  data.frame(
    Variable   = v,
    Moyenne    = round(mean(x, na.rm=TRUE), 2),
    Ecart_type = round(sd(x, na.rm=TRUE), 2),
    Min        = round(min(x, na.rm=TRUE), 2),
    Q25        = round(quantile(x, 0.25, na.rm=TRUE), 2),
    Mediane    = round(median(x, na.rm=TRUE), 2),
    Q75        = round(quantile(x, 0.75, na.rm=TRUE), 2),
```

```
    Q99         = round(quantile(x, 0.99, na.rm=TRUE), 2),
    Max         = round(max(x, na.rm=TRUE), 2)
  )
})) |> kbl_out(caption = "Statistiques descriptives - variables quantitatives")
```

Table 3: Statistiques descriptives — variables quantitatives

	Variable	Moyenne	Ecart_type	Min	Q25	Mediane	Q75	Q99	Max
25%	PERMIS	298.89	162.42	1	163.75	281	422	689.0	940
25%1	ACV	5.96	3.56	0	2.00	7	10	10.0	10
25%2	AGECOND	46.75	14.76	19	34.00	45	57	82.0	103
25%3	RM	65.82	19.36	50	50.00	57	80	118.0	258
25%4	CHARGE	244.02	1406.10	0	0.00	0	0	4395.4	67261

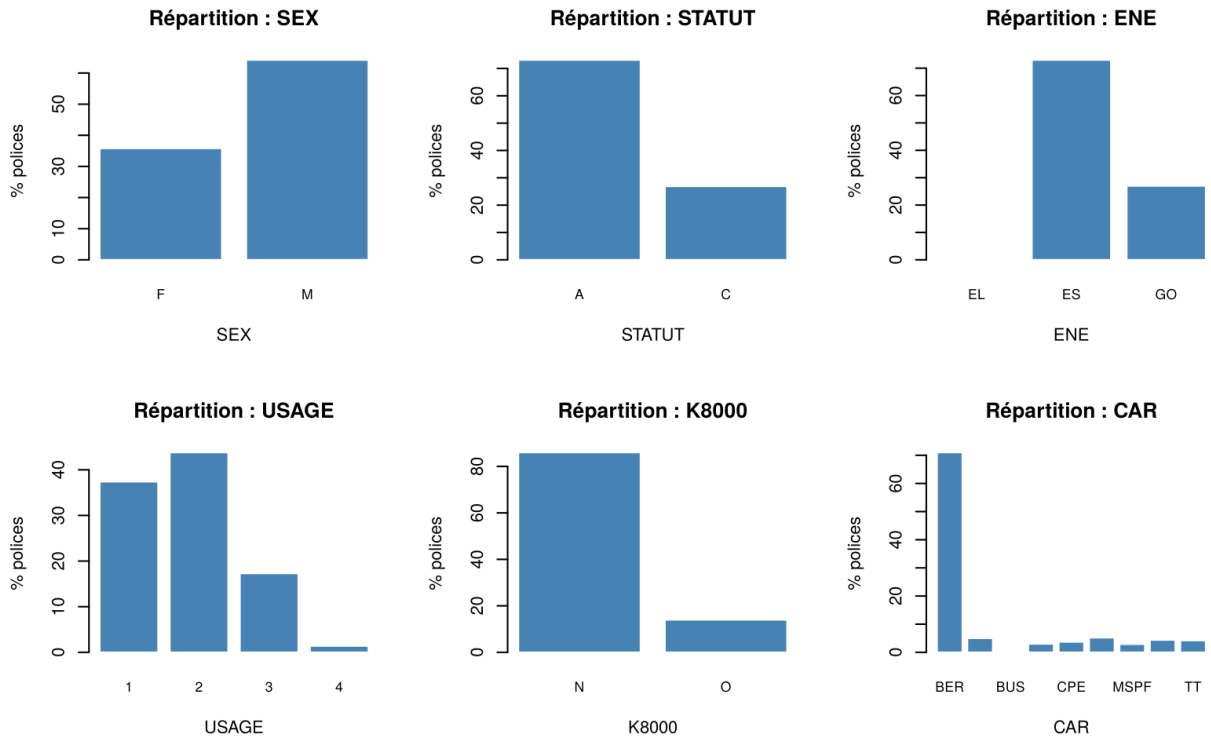
```
par(mfrow = c(2, 3))
cols <- c("steelblue","darkgreen","coral","orange","darkblue")
for (i in seq_along(vars_quanti)) {
  v <- vars_quanti[i]
  hist(df[[v]], probability = TRUE, col = cols[i], border = "white",
       main = paste("Distribution :", v), xlab = v, ylab = "Densité")
  lines(density(df[[v]], na.rm = TRUE), col = "red", lwd = 2)
}
par(mfrow = c(1, 1))
```



Interprétation : La variable **CHARGE** est très asymétrique à droite — 86.7% des polices ont CHARGE = 0 (aucun sinistre sur l'année). Parmi les sinistrés, les montants varient fortement. Le **RM** est concentré entre 50 et 100, témoignant d'un portefeuille globalement bien noté.

1.3.2 Variables qualitatives

```
vars_bar <- c("SEX","STATUT","ENE","USAGE","K8000","CAR")
par(mfrow = c(2, 3))
for (v in vars_bar) {
  tab <- round(prop.table(table(df[[v]])) * 100, 1)
  barplot(tab, col = "steelblue", border = "white",
          main = paste("Répartition :", v),
          xlab = v, ylab = "% polices", cex.names = 0.8)
}
```




```
par(mfrow = c(1, 1))
```

1.4 Regroupements de modalités

1.4.1 (a) CSP → 3 catégories

```
# CAT1 : CSP = 50  |  CAT2 : CSP = 55 ou 60  |  CAT3 : autres
df$CSP3 <- case_when(
  df$CSP == 50           ~ "CAT1",
  df$CSP %in% c(55, 60)  ~ "CAT2",
  TRUE                    ~ "CAT3"
)
df$CSP3 <- factor(df$CSP3, levels = c("CAT1","CAT2","CAT3"))
print(table(df$CSP3))
```

```
CAT1 CAT2 CAT3
6051 2240 2205
```

```r
round(prop.table(table(df$CSP3)) * 100, 2)
```

```
 CAT1  CAT2  CAT3
57.65 21.34 21.01
```

1.4.2 (b) CLA → Eco / Inter / Cher

```r
# Eco : A-G  |  Inter : H-L  |  Cher : toutes les autres modalités
df$CLA3 <- case_when(
  df$CLA %in% c("A","B","C","D","E","F","G") ~ "Eco",
  df$CLA %in% c("H","I","J","K","L")         ~ "Inter",
  TRUE                                         ~ "Cher"
)
df$CLA3 <- factor(df$CLA3, levels = c("Eco","Inter","Cher"))
print(table(df$CLA3))
```

```
  Eco Inter  Cher
 4051  4114  2331
```

```r
round(prop.table(table(df$CLA3)) * 100, 2)
```

```
  Eco Inter  Cher
38.60 39.20 22.21
```

1.4.3 (c) VIT → Lent / VitMoy / Rapide

```r
# VIT est une chaîne de caractères dans BASEAUTO
# Lent : 001-130 à 150-160  |  VitMoy : 160-170 à 180-190  |  Rapide : autres
vit_lent  <- c("001-130","130-140","140-150","150-160")
vit_moyen <- c("160-170","170-180","180-190")

df$VIT3 <- case_when(
  df$VIT %in% vit_lent  ~ "Lent",
  df$VIT %in% vit_moyen ~ "VitMoy",
  TRUE                  ~ "Rapide"
)
df$VIT3 <- factor(df$VIT3, levels = c("Lent","VitMoy","Rapide"))
print(table(df$VIT3))
```

```
  Lent VitMoy Rapide
  3101   4807   2588
```

```r
round(prop.table(table(df$VIT3)) * 100, 2)
```

```
  Lent VitMoy Rapide
 29.54  45.80  24.66
```

1.4.4 (d) CAR → Luxe / Commun / Familial

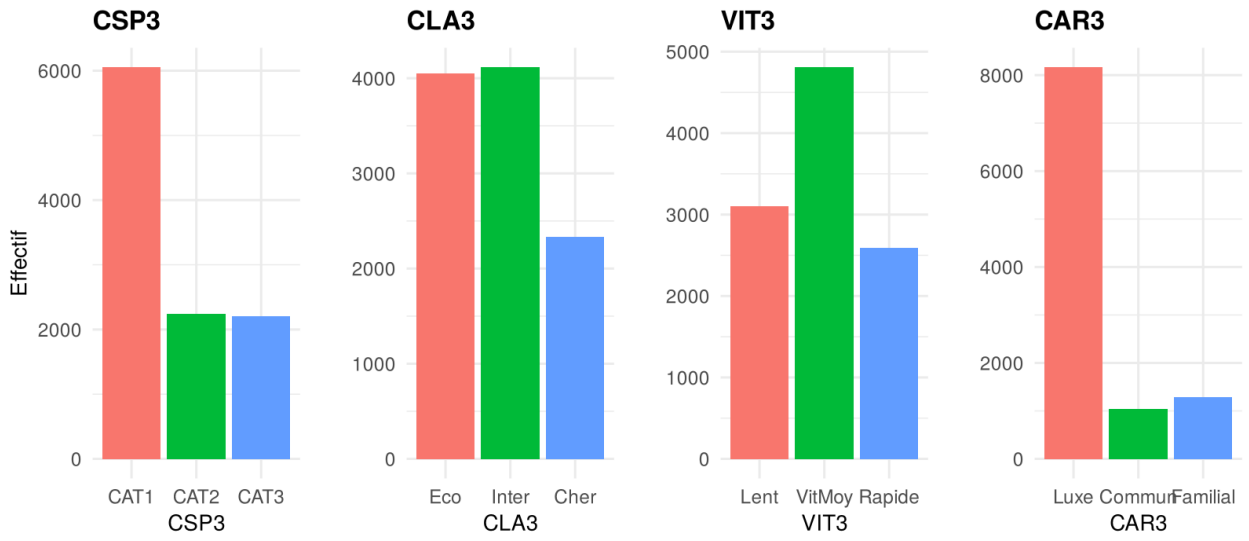
```r
# Luxe : BER, CAB, CPE  |  Commun : CTE, BUS, TT  |  Familial : autres
df$CAR3 <- case_when(
  df$CAR %in% c("BER","CAB","CPE") ~ "Luxe",
  df$CAR %in% c("CTE","BUS","TT")  ~ "Commun",
  TRUE                             ~ "Familial"
)
df$CAR3 <- factor(df$CAR3, levels = c("Luxe","Commun","Familial"))
print(table(df$CAR3))
```

```
    Luxe   Commun Familial
    8161     1042     1293
```

```r
round(prop.table(table(df$CAR3)) * 100, 2)
```

```
    Luxe   Commun Familial
   77.75    9.93    12.32
```

```r
g1 <- ggplot(df, aes(x=CSP3, fill=CSP3)) + geom_bar() +
      labs(title="CSP3", y="Effectif") + theme(legend.position="none")
g2 <- ggplot(df, aes(x=CLA3, fill=CLA3)) + geom_bar() +
      labs(title="CLA3", y="") + theme(legend.position="none")
g3 <- ggplot(df, aes(x=VIT3, fill=VIT3)) + geom_bar() +
      labs(title="VIT3", y="") + theme(legend.position="none")
g4 <- ggplot(df, aes(x=CAR3, fill=CAR3)) + geom_bar() +
      labs(title="CAR3", y="") + theme(legend.position="none")
grid.arrange(g1, g2, g3, g4, ncol=4)
```



1.5 Statistiques descriptives bivariées

```
vars_biv <- c("CSP3","CLA3","VIT3","CAR3","SEX","STATUT","ENE","USAGE")

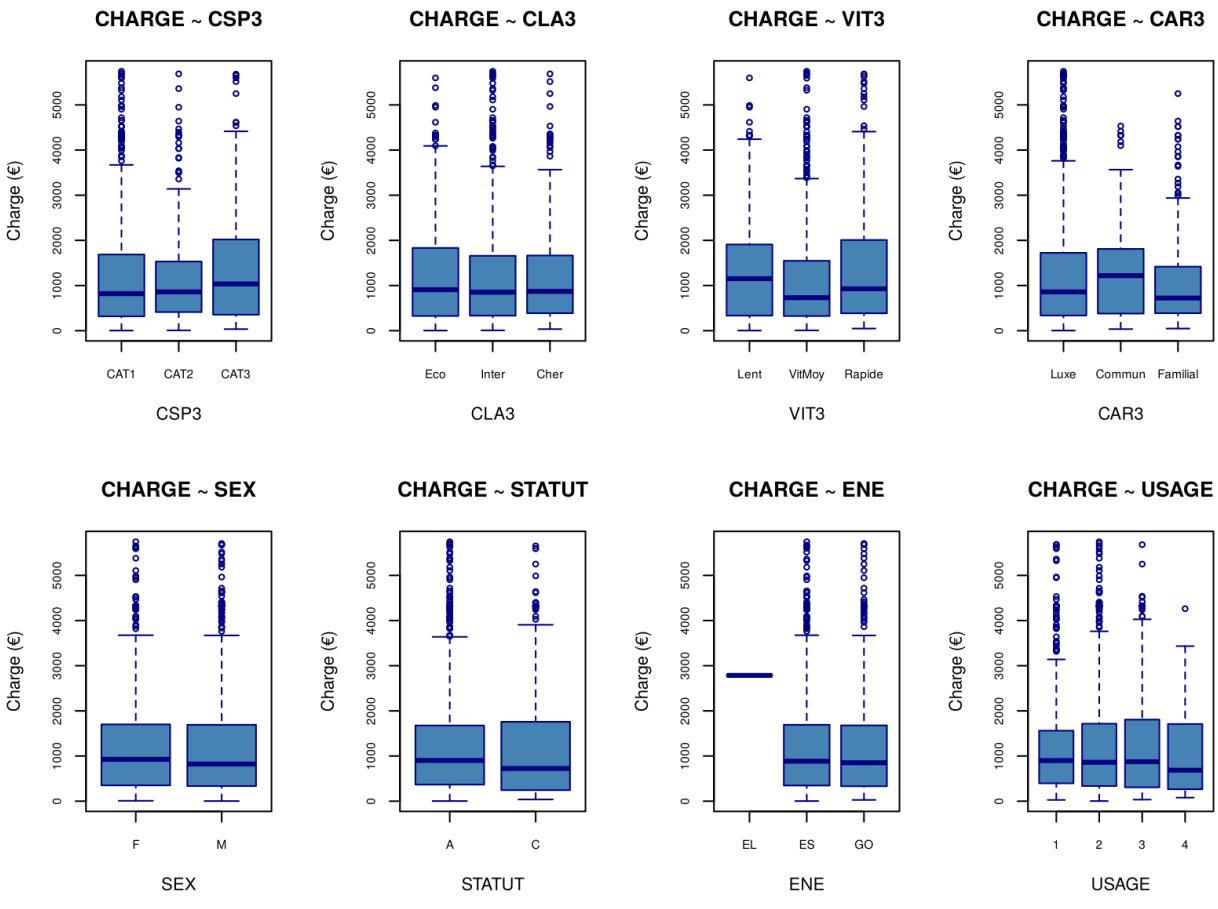
res_biv <- do.call(rbind, lapply(vars_biv, function(v) {
  df |> group_by(Modalite = .data[[v]]) |>
    summarise(N = n(),
              Charge_moy    = round(mean(CHARGE, na.rm=TRUE), 2),
              Freq_sin_pct  = round(mean(CHARGE > 0)*100, 2),
              .groups = "drop") |>
    mutate(Variable = v, .before = 1)
}))

res_biv |> kbl_out(caption = "Charge moyenne et fréquence de sinistre par variable")
```

```
# Zoomer sur les sinistrés (hors extrêmes) pour la lisibilité
df_bv <- df[df$CHARGE > 0 & df$CHARGE < quantile(df$CHARGE[df$CHARGE>0], 0.95), ]
par(mfrow = c(2, 4))
for (v in vars_biv) {
  boxplot(df_bv$CHARGE ~ df_bv[[v]],
          col="steelblue", border="navy", main=paste("CHARGE ~", v),
          xlab=v, ylab="Charge (€)", cex.axis=0.7)
}
```

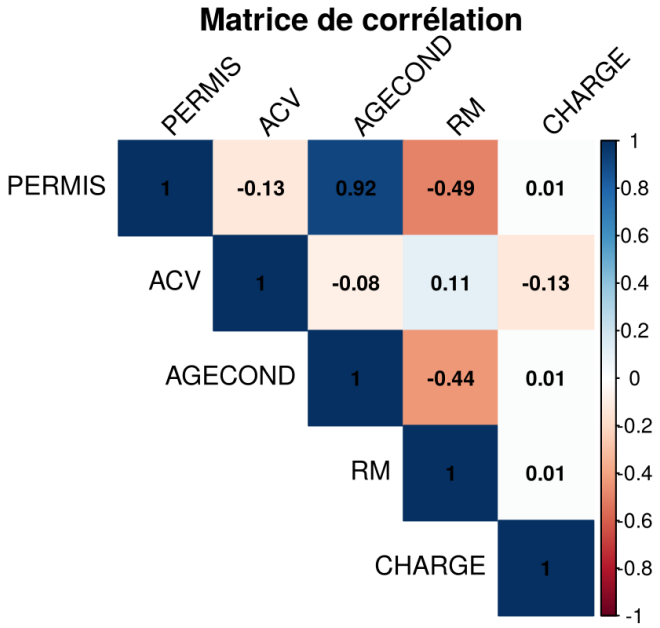
Table 4: Charge moyenne et fréquence de sinistre par variable

Variable	Modalite	N	Charge_moy	Freq_sin_pct
CSP3	CAT1	6051	231.48	12.49
CSP3	CAT2	2240	224.04	14.29
CSP3	CAT3	2205	298.71	14.60
CLA3	Eco	4051	175.09	9.68
CLA3	Inter	4114	265.56	14.75
CLA3	Cher	2331	325.77	17.12
VIT3	Lent	3101	143.53	8.74
VIT3	VitMoy	4807	256.97	14.00
VIT3	Rapide	2588	340.36	17.54
CAR3	Luxe	8161	226.62	12.77
CAR3	Commun	1042	328.44	14.49
CAR3	Familial	1293	285.79	15.85
SEX	F	3761	249.79	13.61
SEX	M	6735	240.79	13.16
STATUT	A	7668	257.21	13.91
STATUT	C	2828	208.25	11.70
ENE	EL	2	1392.50	50.00
ENE	ES	7665	211.73	12.29
ENE	GO	2829	330.67	16.08
USAGE	1	3929	183.78	10.89
USAGE	2	4600	240.29	12.74
USAGE	3	1819	365.25	19.19
USAGE	4	148	468.82	23.65



```r
par(mfrow = c(1, 1))
```

```r
mat_cor <- cor(df[, c("PERMIS","ACV","AGECOND","RM","CHARGE")], use="complete.obs")
corrplot(mat_cor, method="color", type="upper", addCoef.col="black",
         number.cex=0.8, tl.col="black", tl.srt=45,
         title="Matrice de corrélation", mar=c(0,0,1,0))
```



1.6 À quoi servent les analyses préliminaires ?

Type	Utilité
Univariée	Comprendre la distribution, détecter les valeurs aberrantes, identifier les modalités rares à regrouper
Bivariée	Mesurer l'effet brut de chaque variable sur la charge → discrimination tarifaire
Corrélation	Détecter la multicolinéarité → risque d'instabilité du GLM
Stabilité temporelle	Vérifier que le portefeuille n'a pas dérivé dans le temps → stationnarité nécessaire

---

2 Partie B — Préparation à la modélisation

2.1 Profil de référence

```
vars_pr <- c("SEX","STATUT","USAGE","CAR3","CLA3","VIT3","ENE","K8000","GARAGE","CSP3")
profil <- data.frame(
  Variable  = vars_pr,
  Reference = sapply(vars_pr, function(v) names(which.max(table(df[[v]])))),
  Effectif  = sapply(vars_pr, function(v) max(table(df[[v]])))
)
profil$Pct <- round(profil$Effectif / nrow(df) * 100, 1)

profil |> kbl_out(caption = "Profil de référence du portefeuille")
```

Table 6: Profil de référence du portefeuille

	Variable	Reference	Effectif	Pct
SEX	SEX	M	6735	64.2
STATUT	STATUT	A	7668	73.1
USAGE	USAGE	2	4600	43.8
CAR3	CAR3	Luxe	8161	77.8
CLA3	CLA3	Inter	4114	39.2
VIT3	VIT3	VitMoy	4807	45.8
ENE	ENE	ES	7665	73.0
K8000	K8000	N	9023	86.0
GARAGE	GARAGE	3	7602	72.4
CSP3	CSP3	CAT1	6051	57.7

Le profil de référence correspond à l'assuré le plus représentatif du portefeuille : conducteur **M**, statut **A**, usage **2**, véhicule **Luxe**, classe SRA **Inter**, vitesse **VitMoy**, énergie **ES**.

2.2 Séparation sinistres attritionnels / graves

```
# Base des sinistrés uniquement
df_sin <- subset(df, CHARGE > 0)
cat("Nombre total de sinistrés :", nrow(df_sin), "\n")
```

```
Nombre total de sinistrés : 1398
```

```
# Seuil : percentile 99 de la charge conditionnelle
limite <- quantile(df_sin$CHARGE, 0.99)
cat("Seuil Q99 :", round(limite, 2), "euros\n")
```

```
Seuil Q99 : 17490.47 euros
```

Justification du seuil : On retient le **99e percentile** (1.749×10^4 €). Au-delà, les sinistres présentent une volatilité extrême incompatible avec la loi Gamma. Ces sinistres graves (1% des sinistrés) sont gérés séparément via un chargement ou la réassurance.

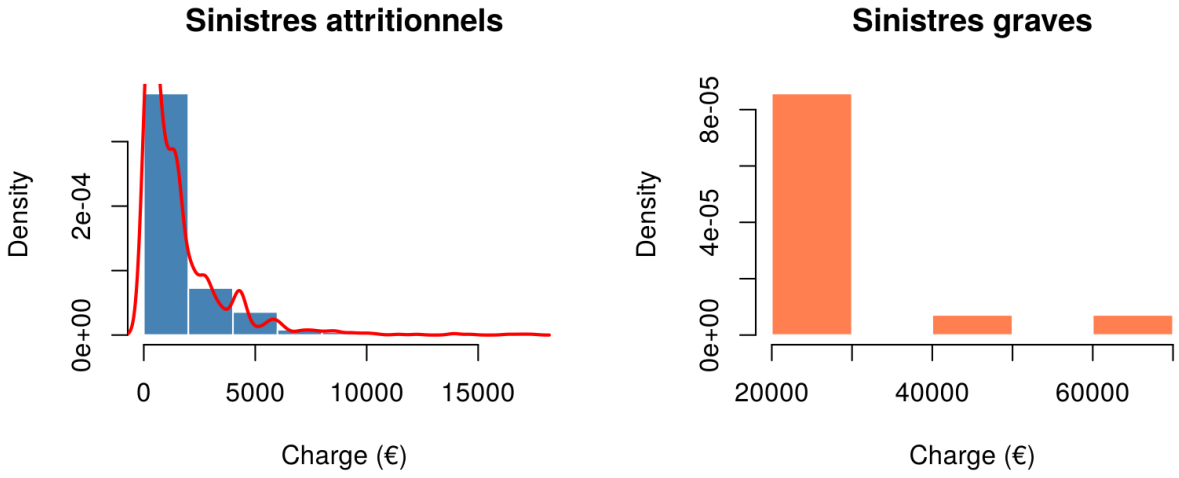
```
df_attri  <- df_sin[df_sin$CHARGE <= limite, ]
df_graves <- df_sin[df_sin$CHARGE >  limite, ]

rbind(
  data.frame(Base="Attritionnels", N=nrow(df_attri),
             Min=round(min(df_attri$CHARGE),0),
             Moy=round(mean(df_attri$CHARGE),0),
             Max=round(max(df_attri$CHARGE),0)),
  data.frame(Base="Graves", N=nrow(df_graves),
             Min=round(min(df_graves$CHARGE),0),
             Moy=round(mean(df_graves$CHARGE),0),
             Max=round(max(df_graves$CHARGE),0))
) |> kbl_out(caption = "Caractéristiques des deux bases")
```

Table 7: Caractéristiques des deux bases

Base	N	Min	Moy	Max
Attritionnels	1384	3	1576	17408
Graves	14	20157	27159	67261

```
par(mfrow = c(1, 2))
hist(df_attri$CHARGE,  col="steelblue", border="white", probability=TRUE,
     main="Sinistres attritionnels", xlab="Charge (€)")
lines(density(df_attri$CHARGE), col="red", lwd=2)
hist(df_graves$CHARGE, col="coral",     border="white", probability=TRUE,
     main="Sinistres graves", xlab="Charge (€)")
```



```r
par(mfrow = c(1, 1))
```

2.3 Base de construction du tarif

Le tarif est construit sur la **base attritionnelle** (1384 sinistres). Les sinistres graves sont traités via un **chargement additionnel** ou la **réassurance**.

2.4 Échantillons apprentissage / test

```r
set.seed(2025)
n      <- nrow(df_attri)
idx_tr <- sample(seq_len(n), size = round(0.80 * n))
train  <- df_attri[ idx_tr, ]
test   <- df_attri[-idx_tr, ]

cat("Apprentissage :", nrow(train), "obs. (80%) | Test :", nrow(test), "obs. (20%)\n")
```

```
Apprentissage : 1107 obs. (80%) | Test : 277 obs. (20%)
```

2.5 Tests d'adéquation de la charge

```r
# -- Base : tous les sinistres attritionnels (> 0, <= seuil Q99) --------------
charge_pos <- df_attri$CHARGE[df_attri$CHARGE > 0]
n_cp       <- length(charge_pos)
cat("N observations :", n_cp, "| Min :", round(min(charge_pos), 2),
    "| Max :", round(max(charge_pos), 2), "\n")
```

```
N observations : 1384 | Min : 3 | Max : 17408
```

```r
# -- Estimation par maximum de vraisemblance pour les trois lois --------------
# Les montants sont mis à l'échelle (k€) pour stabiliser l'optimisation,
# puis la log-vraisemblance est corrigée du jacobien du changement d'échelle.
ech <- 1000
xs  <- charge_pos / ech

fit_g <- fitdistr(xs, "gamma")
fit_l <- fitdistr(charge_pos, "lognormal")
fit_w <- fitdistr(xs, "weibull")

shape_g <- unname(fit_g$estimate["shape"])
rate_g  <- unname(fit_g$estimate["rate"]) / ech
meanlog <- unname(fit_l$estimate["meanlog"])
sdlog   <- unname(fit_l$estimate["sdlog"])
shape_w <- unname(fit_w$estimate["shape"])
scale_w <- unname(fit_w$estimate["scale"]) * ech

ll <- c(
  Gamma         = sum(dgamma(charge_pos, shape = shape_g, rate = rate_g, log = TRUE)),
  `Log-normale` = sum(dlnorm(charge_pos, meanlog = meanlog, sdlog = sdlog, log = TRUE)),
  Weibull       = sum(dweibull(charge_pos, shape = shape_w, scale = scale_w, log = TRUE))
)
k <- 2  # deux paramètres pour chaque loi

comp <- data.frame(
  Loi      = names(ll),
  LogVrais = round(ll, 2),
  AIC      = round(-2 * ll + 2 * k, 2),
  BIC      = round(-2 * ll + k * log(n_cp), 2),
  row.names = NULL
)
comp$Meilleure <- ifelse(comp$AIC == min(comp$AIC), " ", "")
comp |> kbl_out(caption = "Comparaison des lois (maximum de vraisemblance) - AIC, BIC")
```

Table 8: Comparaison des lois (maximum de vraisemblance) — AIC, BIC

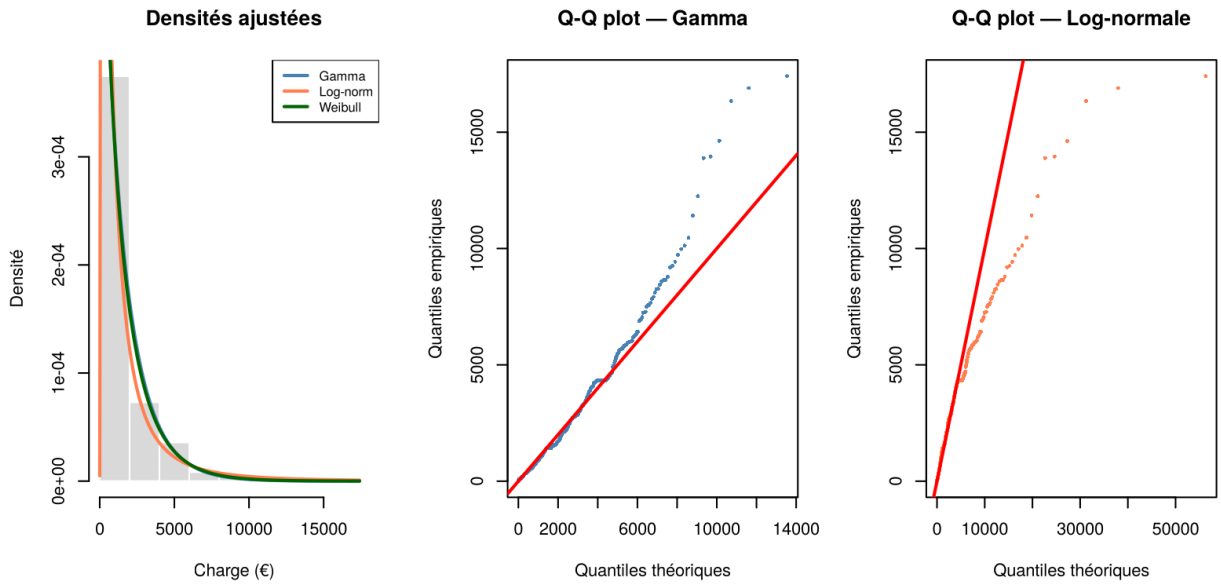
Loi	LogVrais	AIC	BIC	Meilleure
Gamma	-11566.62	23137.24	23147.70	
Log-normale	-11549.54	23103.08	23113.55	
Weibull	-11558.32	23120.65	23131.11	

```r
loi_aic <- comp$Loi[which.min(comp$AIC)]
ecart_aic_gamma <- round(comp$AIC[comp$Loi == "Gamma"] - min(comp$AIC), 1)
```

```r
par(mfrow = c(1, 3))
x_seq <- seq(min(charge_pos), max(charge_pos), length.out = 300)
```

```r
# 1. Densité empirique vs densités ajustées
hist(charge_pos, probability = TRUE, col = "grey85", border = "white",
     main = "Densités ajustées", xlab = "Charge (€)", ylab = "Densité")
lines(x_seq, dgamma(x_seq, shape = shape_g, rate = rate_g),       col = "steelblue", lwd = 2)
lines(x_seq, dlnorm(x_seq, meanlog = meanlog, sdlog = sdlog),     col = "coral",     lwd = 2)
lines(x_seq, dweibull(x_seq, shape = shape_w, scale = scale_w),   col = "darkgreen", lwd = 2)
legend("topright", legend = c("Gamma","Log-norm","Weibull"),
       col = c("steelblue","coral","darkgreen"), lwd = 2, cex = 0.75)

# 2. Q-Q plots Gamma et log-normale
pp <- ppoints(n_cp); q_emp <- sort(charge_pos)
plot(qgamma(pp, shape = shape_g, rate = rate_g), q_emp, pch = 16, cex = 0.5,
     col = "steelblue", main = "Q-Q plot - Gamma",
     xlab = "Quantiles théoriques", ylab = "Quantiles empiriques")
abline(0, 1, col = "red", lwd = 2)
plot(qlnorm(pp, meanlog = meanlog, sdlog = sdlog), q_emp, pch = 16, cex = 0.5,
     col = "coral", main = "Q-Q plot - Log-normale",
     xlab = "Quantiles théoriques", ylab = "Quantiles empiriques")
abline(0, 1, col = "red", lwd = 2)
```




```r
par(mfrow = c(1, 1))
```

```r
# -- Test de Kolmogorov-Smirnov ----------------------------------------------
# Les paramètres étant estimés sur les mêmes données, les p-values du test KS
# classique sont optimistes (problème de Lilliefors) : on les complète par un
# bootstrap paramétrique (B = 200) qui ré-estime les paramètres à chaque tirage.
set.seed(2025)
B <- 200
```

```r
ks_boot <- function(rgen, refit, pfun, d_obs) {
  d_b <- replicate(B, {
    xb <- rgen(n_cp)
    th <- refit(xb)
    suppressWarnings(ks.test(xb, pfun, th[1], th[2])$statistic)
  })
  mean(d_b >= d_obs)
}

d_g <- suppressWarnings(ks.test(charge_pos, "pgamma", shape_g, rate_g))
d_l <- suppressWarnings(ks.test(charge_pos, "plnorm", meanlog, sdlog))

p_boot_g <- ks_boot(function(n) rgamma(n, shape_g, rate_g),
                    function(x) { f <- fitdistr(x / ech, "gamma")$estimate
                                  c(f[1], f[2] / ech) },
                    "pgamma", d_g$statistic)
p_boot_l <- ks_boot(function(n) rlnorm(n, meanlog, sdlog),
                    function(x) c(mean(log(x)), sqrt(mean((log(x) - mean(log(x)))^2))),
                    "plnorm", d_l$statistic)

data.frame(
  Loi            = c("Gamma", "Log-normale"),
  Statistique_D  = round(c(d_g$statistic, d_l$statistic), 4),
  p_KS_classique = round(c(d_g$p.value, d_l$p.value), 4),
  p_bootstrap    = round(c(p_boot_g, p_boot_l), 3)
) |> kbl_out(caption = "Tests de Kolmogorov-Smirnov (classique et bootstrap paramétrique)")
```

Table 9: Tests de Kolmogorov-Smirnov (classique et bootstrap paramétrique)

Loi	Statistique_D	p_KS_classique	p_bootstrap
Gamma	0.0652	0	0
Log-normale	0.0716	0	0

Interprétation : Au sens de l'AIC, la meilleure loi est la **Log-normale** (écart d'AIC avec la Gamma : 34.2 points). Pour le GLM coût, on retient néanmoins la **famille Gamma avec lien log** : elle modélise directement l'espérance du coût (sans biais de retransformation, contrairement à une régression sur log(CHARGE)), donne des effets multiplicatifs lisibles et constitue le standard de la tarification non-vie. Une régression log-normale pourrait être testée en variante.

Le test KS (p-value bootstrap : 0 pour la Gamma, 0 pour la log-normale) rejette les deux lois au seuil de 5 % : avec plus de 1 300 observations, le test détecte des écarts même modérés, visibles sur les Q-Q plots dans la queue droite. Aucune loi paramétrique simple ne décrit parfaitement la charge ; la Gamma est utilisée ici comme hypothèse de travail pour le GLM, ce qui est une limite à garder en tête.

---

3 Partie C — Modélisation GLM

3.1 GLM Fréquence — Loi Binomiale / Lien logit

```r
# Base complète (sinistrés + non sinistrés) avec l'indicateur binaire
df_freq <- df
df_freq$indicateur <- as.integer(df_freq$CHARGE > 0)
cat("Taux de sinistralité :", round(mean(df_freq$indicateur)*100, 2), "%\n")
```

```
Taux de sinistralité : 13.32 %
```

```r
# Profil de référence → modalités les plus fréquentes
df_freq$SEX    <- relevel(as.factor(df_freq$SEX),    ref = "M")
df_freq$STATUT <- relevel(as.factor(df_freq$STATUT), ref = "A")
df_freq$USAGE  <- relevel(as.factor(df_freq$USAGE),  ref = "2")
df_freq$K8000  <- relevel(as.factor(df_freq$K8000),  ref = "N")
df_freq$ENE    <- relevel(as.factor(df_freq$ENE),    ref = "ES")
df_freq$GARAGE <- relevel(as.factor(df_freq$GARAGE), ref = "3")
df_freq$CSP3   <- relevel(as.factor(df_freq$CSP3),   ref = "CAT1")
df_freq$CLA3   <- relevel(as.factor(df_freq$CLA3),   ref = "Inter")
df_freq$VIT3   <- relevel(as.factor(df_freq$VIT3),   ref = "VitMoy")
df_freq$CAR3   <- relevel(as.factor(df_freq$CAR3),   ref = "Luxe")

# Split 80/20
set.seed(2025)
idx_f   <- sample(seq_len(nrow(df_freq)), round(0.8 * nrow(df_freq)))
train_f <- df_freq[ idx_f, ]
test_f  <- df_freq[-idx_f, ]
```

```r
formule_freq <- indicateur ~ CSP3 + CLA3 + VIT3 + CAR3 +
                SEX + STATUT + USAGE + K8000 + ENE + GARAGE +
                RM + AGECOND + PERMIS + ACV

mod_freq <- glm(formule_freq, family = binomial(link = "logit"),
                data = train_f, na.action = na.omit)
summary(mod_freq)
```

```
Call:
glm(formula = formule_freq, family = binomial(link = "logit"),
    data = train_f, na.action = na.omit)

Coefficients:
               Estimate Std. Error z value Pr(>|z|)
(Intercept)  -0.9731301  0.2519731  -3.862 0.000112 ***
```

```
CSP3CAT2      0.1149668  0.0996849   1.153 0.248786
CSP3CAT3     -0.0257251  0.0895963  -0.287 0.774019
CLA3Eco      -0.1344530  0.0998455  -1.347 0.178106
CLA3Cher      0.1960901  0.0984201   1.992 0.046329 *
VIT3Lent     -0.1630715  0.1009676  -1.615 0.106292
VIT3Rapide   -0.0290369  0.0958662  -0.303 0.761974
CAR3Commun   -0.1365380  0.1284981  -1.063 0.287978
CAR3Familial -0.1386715  0.1060674  -1.307 0.191080
SEXF          0.2180716  0.0740779   2.944 0.003242 **
STATUTC       0.0670088  0.0873230   0.767 0.442863
USAGE1       -0.1933125  0.0886707  -2.180 0.029249 *
USAGE3        0.1167930  0.0957193   1.220 0.222404
USAGE4        0.1582772  0.2472160   0.640 0.522018
K80000       -0.5059800  0.1315542  -3.846 0.000120 ***
ENEEL         2.1128401  1.4200843   1.488 0.136796
ENEGO         0.0324956  0.0803708   0.404 0.685977
GARAGE1      -0.0324883  0.1101530  -0.295 0.768041
GARAGE2      -0.0041644  0.0903080  -0.046 0.963220
RM            0.0029233  0.0019971   1.464 0.143253
AGECOND      -0.0068252  0.0066382  -1.028 0.303870
PERMIS        0.0011496  0.0005844   1.967 0.049186 *
ACV          -0.2173764  0.0112651 -19.296  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 6633.4  on 8396  degrees of freedom
Residual deviance: 5963.6  on 8374  degrees of freedom
AIC: 6009.6

Number of Fisher Scoring iterations: 5
```

```r
# Sélection pas-à-pas par AIC
mod_freq_opt <- stepAIC(mod_freq, direction = "both", trace = FALSE)
cat("=== GLM Fréquence optimisé ===\n")
```

```
=== GLM Fréquence optimisé ===
```

```r
summary(mod_freq_opt)
```

```
Call:
glm(formula = indicateur ~ CLA3 + VIT3 + SEX + USAGE + K8000 +
    RM + PERMIS + ACV, family = binomial(link = "logit"), data = train_f,
    na.action = na.omit)
```

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -1.1606128  0.1917436  -6.053 1.42e-09 ***
CLA3Eco     -0.0918425  0.0920087  -0.998 0.318185
CLA3Cher     0.1413242  0.0901885   1.567 0.117118
VIT3Lent    -0.1868973  0.0967534  -1.932 0.053398 .
VIT3Rapide   0.0151370  0.0876229   0.173 0.862846
SEXF         0.2183210  0.0731376   2.985 0.002835 **
USAGE1      -0.1939700  0.0844788  -2.296 0.021671 *
USAGE3       0.0710572  0.0894193   0.795 0.426816
USAGE4       0.1104193  0.2417598   0.457 0.647864
K8000O      -0.5073327  0.1310739  -3.871 0.000109 ***
RM           0.0032482  0.0019704   1.648 0.099261 .
PERMIS       0.0006665  0.0002503   2.663 0.007743 **
ACV         -0.2162947  0.0110307 -19.608  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 6633.4  on 8396  degrees of freedom
Residual deviance: 5971.5  on 8384  degrees of freedom
AIC: 5997.5

Number of Fisher Scoring iterations: 5
```

```
anova(mod_freq_opt, test = "Chisq") |> as.data.frame() |> round(4) |>
  kbl_out(caption = "Analyse de la déviance - GLM Fréquence")
```

Table 10: Analyse de la déviance — GLM Fréquence

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL	NA	NA	8396	6633.397	NA
CLA3	2	65.0096	8394	6568.388	0.0000
VIT3	2	29.1004	8392	6539.287	0.0000
SEX	1	13.1839	8391	6526.103	0.0003
USAGE	3	57.2126	8388	6468.891	0.0000
K8000	1	38.5800	8387	6430.311	0.0000
RM	1	1.3881	8386	6428.923	0.2387
PERMIS	1	17.4532	8385	6411.469	0.0000
ACV	1	439.9287	8384	5971.541	0.0000

```
ic_freq <- confint(mod_freq_opt, level = 0.95)
data.frame(
  Coeff    = round(coef(mod_freq_opt), 4),
  OR       = round(exp(coef(mod_freq_opt)), 4),
```

```
  IC_inf   = round(exp(ic_freq[,1]), 4),
  IC_sup   = round(exp(ic_freq[,2]), 4)
) |> kbl_out(caption = "Odds-Ratios et IC 95% - GLM Fréquence")
```

\begin{table}[!h] \caption{Odds-Ratios et IC 95% — GLM Fréquence}

	Coeff	OR	IC_inf	IC_sup
(Intercept)	-1.1606	0.3133	0.2154	0.4567
CLA3Eco	-0.0918	0.9122	0.7613	1.0921
CLA3Cher	0.1413	1.1518	0.9647	1.3740
VIT3Lent	-0.1869	0.8295	0.6855	1.0018
VIT3Rapide	0.0151	1.0153	0.8547	1.2051
SEXF	0.2183	1.2440	1.0775	1.4353
USAGE1	-0.1940	0.8237	0.6976	0.9715
USAGE3	0.0711	1.0736	0.9003	1.2784
USAGE4	0.1104	1.1167	0.6829	1.7682
K8000O	-0.5073	0.6021	0.4626	0.7738
RM	0.0032	1.0033	0.9993	1.0071
PERMIS	0.0007	1.0007	1.0002	1.0012
ACV	-0.2163	0.8055	0.7881	0.8230

\end{table}

```
pred_f <- predict(mod_freq_opt, newdata = test_f, type = "response")
cat("Fréquence prédite :", round(mean(pred_f), 4), "\n")
```

```
Fréquence prédite : 0.1336
```

```
cat("Fréquence observée:", round(mean(test_f$indicateur), 4), "\n")
```

```
Fréquence observée: 0.1277
```

```
cat("Écart relatif     :",
    round(abs(mean(pred_f)-mean(test_f$indicateur))/mean(test_f$indicateur)*100, 2), "%\n")
```

```
Écart relatif     : 4.61 %
```

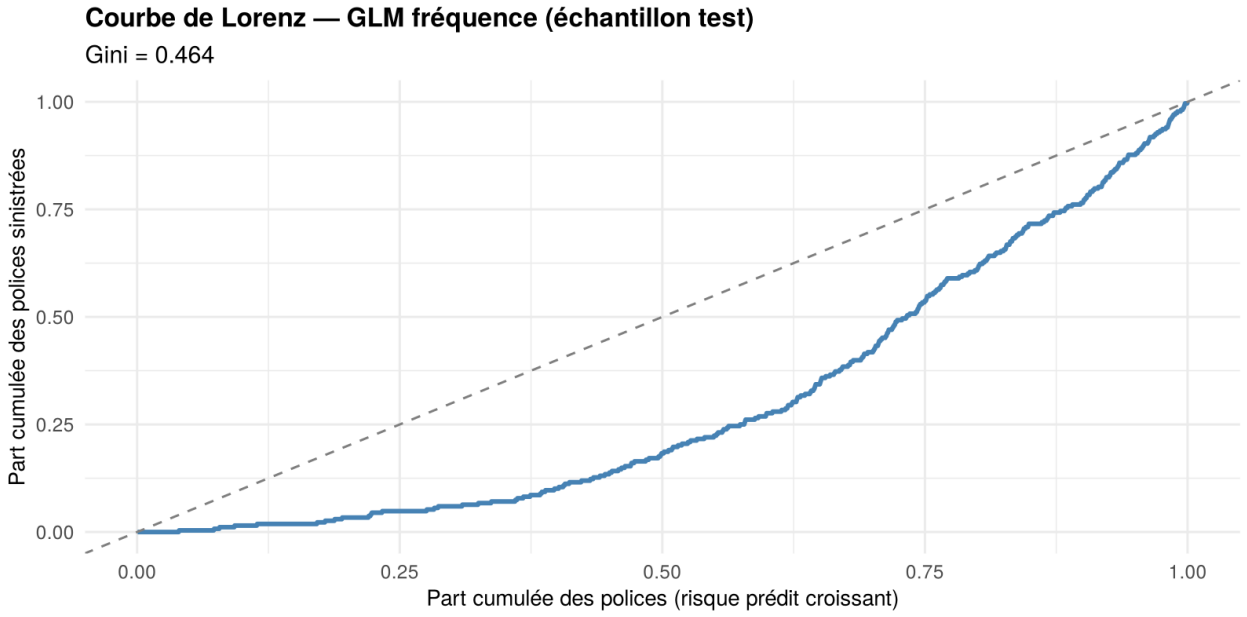
```
# -- Pouvoir discriminant sur l'échantillon test : AUC, Gini, courbe de Lorenz -
auc_fun <- function(y, p) {
  r <- rank(p); n1 <- sum(y == 1); n0 <- sum(y == 0)
  (sum(r[y == 1]) - n1 * (n1 + 1) / 2) / (n1 * n0)
}
auc_f  <- auc_fun(test_f$indicateur, pred_f)
gini_f <- 2 * auc_f - 1
cat("AUC (test)  :", round(auc_f, 3), "\n")
```

```
AUC (test)  : 0.732
```

```r
cat("Gini (test) :", round(gini_f, 3), "\n")
```

```
Gini (test) : 0.464
```

```r
# Courbe de Lorenz ordonnée : polices triées du risque prédit le plus faible au plus fort
o   <- order(pred_f)
lor <- data.frame(part_polices   = seq_along(o) / length(o),
                  part_sinistres = cumsum(test_f$indicateur[o]) / sum(test_f$indicateur))
ggplot(lor, aes(part_polices, part_sinistres)) +
  geom_line(colour = "steelblue", linewidth = 1) +
  geom_abline(linetype = "dashed", colour = "grey50") +
  labs(title = "Courbe de Lorenz - GLM fréquence (échantillon test)",
       subtitle = paste0("Gini = ", round(gini_f, 3)),
       x = "Part cumulée des polices (risque prédit croissant)",
       y = "Part cumulée des polices sinistrées")
```



Interprétation : Les odds-ratios > 1 indiquent une hausse de la probabilité de sinistre par rapport au profil de référence. Les variables retenues par stepAIC sont celles qui améliorent le critère AIC ; leur apport individuel se lit dans le tableau d'analyse de la déviance. Sur l'échantillon test, le modèle atteint un Gini de 0.46 : il classe correctement les polices par niveau de risque.

3.2 GLM Coût — Loi Gamma / Lien log

```r
# Base attritionnelle - apprentissage
train_c <- train

train_c$SEX    <- relevel(as.factor(train_c$SEX),    ref = "M")
train_c$STATUT <- relevel(as.factor(train_c$STATUT), ref = "A")
train_c$USAGE  <- relevel(as.factor(train_c$USAGE),  ref = "2")
train_c$K8000  <- relevel(as.factor(train_c$K8000),  ref = "N")
train_c$ENE    <- relevel(as.factor(train_c$ENE),    ref = "ES")
train_c$GARAGE <- relevel(as.factor(train_c$GARAGE), ref = "3")
train_c$CSP3   <- relevel(as.factor(train_c$CSP3),   ref = "CAT1")
train_c$CLA3   <- relevel(as.factor(train_c$CLA3),   ref = "Inter")
train_c$VIT3   <- relevel(as.factor(train_c$VIT3),   ref = "VitMoy")
train_c$CAR3   <- relevel(as.factor(train_c$CAR3),   ref = "Luxe")

cat("Base coût apprentissage :", nrow(train_c), "obs.\n")
```

```
Base coût apprentissage : 1107 obs.
```

```r
formule_cout <- CHARGE ~ CSP3 + CLA3 + VIT3 + CAR3 +
                SEX + STATUT + USAGE + K8000 + ENE + GARAGE +
                RM + AGECOND + PERMIS + ACV

mod_cout <- glm(formule_cout, family = Gamma(link = "log"),
                data = train_c, na.action = na.omit)
summary(mod_cout)
```

```
Call:
glm(formula = formule_cout, family = Gamma(link = "log"), data = train_c,
    na.action = na.omit)

Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)   6.5564976  0.2745513  23.881  < 2e-16 ***
CSP3CAT2     -0.0452568  0.1146968  -0.395   0.6932
CSP3CAT3      0.1036434  0.0976896   1.061   0.2890
CLA3Eco      -0.1350167  0.1099725  -1.228   0.2198
CLA3Cher     -0.0285720  0.1095909  -0.261   0.7944
VIT3Lent      0.0987361  0.1099422   0.898   0.3693
VIT3Rapide    0.1737358  0.1048496   1.657   0.0978 .
CAR3Commun    0.0175588  0.1400326   0.125   0.9002
CAR3Familial  0.0846203  0.1181365   0.716   0.4740
SEXF          0.0395808  0.0817596   0.484   0.6284
STATUTC      -0.1668483  0.0999016  -1.670   0.0952 .
USAGE1       -0.0184193  0.1038227  -0.177   0.8592
USAGE3       -0.0553389  0.1050375  -0.527   0.5984
```

```
USAGE4        0.0454650  0.2460850   0.185   0.8535
K8000O        0.1165896  0.1578941   0.738   0.4604
ENEEL         0.7339042  1.2345459   0.594   0.5523
ENEGO         0.1224308  0.0888373   1.378   0.1684
GARAGE1       0.0422757  0.1266836   0.334   0.7387
GARAGE2      -0.0528169  0.0988506  -0.534   0.5932
RM            0.0083474  0.0020338   4.104 4.36e-05 ***
AGECOND       0.0048295  0.0075607   0.639   0.5231
PERMIS       -0.0001055  0.0006569  -0.161   0.8724
ACV          -0.0006476  0.0144075  -0.045   0.9642
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Gamma family taken to be 1.488772)

    Null deviance: 1492.5  on 1106  degrees of freedom
Residual deviance: 1443.1  on 1084  degrees of freedom
AIC: 18533

Number of Fisher Scoring iterations: 7
```

```r
mod_cout_opt <- stepAIC(mod_cout, direction = "both", trace = FALSE)
cat("=== GLM Coût optimisé ===\n")
```

```
=== GLM Coût optimisé ===
```

```r
summary(mod_cout_opt)
```

```

Call:
glm(formula = CHARGE ~ VIT3 + STATUT + RM, family = Gamma(link = "log"),
    data = train_c, na.action = na.omit)

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  6.821349   0.130948  52.092  < 2e-16 ***
VIT3Lent     0.060804   0.099182   0.613  0.53997
VIT3Rapide   0.153764   0.084291   1.824  0.06839 .
STATUTC     -0.239329   0.090591  -2.642  0.00836 **
RM           0.008197   0.001909   4.294 1.91e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Gamma family taken to be 1.513365)

    Null deviance: 1492.5  on 1106  degrees of freedom
```

```
Residual deviance: 1457.4  on 1102  degrees of freedom
AIC: 18510

Number of Fisher Scoring iterations: 6
```

```
anova(mod_cout_opt, test = "Chisq") |> as.data.frame() |> round(4) |>
  kbl_out(caption = "Analyse de la déviance - GLM Coût")
```

Table 11: Analyse de la déviance — GLM Coût

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL	NA	NA	1106	1492.497	NA
VIT3	2	3.8725	1104	1488.624	0.2782
STATUT	1	3.2031	1103	1485.421	0.1457
RM	1	28.0052	1102	1457.416	0.0000

```
ic_cout <- confint(mod_cout_opt, level = 0.95)
data.frame(
  Coeff         = round(coef(mod_cout_opt), 4),
  Multiplicateur = round(exp(coef(mod_cout_opt)), 4),
  IC_inf        = round(exp(ic_cout[,1]), 4),
  IC_sup        = round(exp(ic_cout[,2]), 4)
) |> kbl_out(caption = "Multiplicateurs et IC 95% - GLM Coût (Gamma)")
```

\begin{table}[!h] \caption{Multiplicateurs et IC 95% — GLM Coût (Gamma)}

	Coeff	Multiplicateur	IC_inf	IC_sup
(Intercept)	6.8213	917.2218	703.1658	1192.3858
VIT3Lent	0.0608	1.0627	0.8758	1.2961
VIT3Rapide	0.1538	1.1662	0.9894	1.3770
STATUTC	-0.2393	0.7872	0.6594	0.9441
RM	0.0082	1.0082	1.0044	1.0122

\end{table}

```
test_c <- test
for (v in c("SEX","STATUT","USAGE","K8000","ENE","GARAGE",
            "CSP3","CLA3","VIT3","CAR3")) {
  test_c[[v]] <- factor(test_c[[v]], levels = levels(train_c[[v]]))
}
pred_c <- predict(mod_cout_opt, newdata = test_c, type = "response")
cat("Coût moyen prédit  :", round(mean(pred_c, na.rm=TRUE), 2), "€\n")
```

```
Coût moyen prédit  : 1609.42 €
```

```
cat("Coût moyen observé :", round(mean(test$CHARGE), 2), "€\n")
```

```
Coût moyen observé : 1542.96 €
```

```r
cat("Écart relatif      :",
    round(abs(mean(pred_c,na.rm=TRUE)-mean(test$CHARGE))/mean(test$CHARGE)*100, 2), "%\n")
```

```
Écart relatif      : 4.31 %
```

Interprétation : Les multiplicateurs (exp(coef)) quantifient le ratio du coût moyen par rapport au profil de référence. Un multiplicateur de 1,30 signifie +30% de coût moyen toutes choses égales par ailleurs.

3.3 Prise en compte des sinistres graves

```r
# Les sinistres graves (> Q99) sont exclus du GLM coût : leur coût est réparti
# uniformément sur l'ensemble du portefeuille sous forme de surprime.
surprime_graves <- sum(df_graves$CHARGE) / nrow(df)
cat("Charge totale des sinistres graves :", round(sum(df_graves$CHARGE), 0), "€\n")
```

```
Charge totale des sinistres graves : 380226 €
```

```r
cat("Surprime « graves » par police     :", round(surprime_graves, 2), "€\n")
```

```
Surprime « graves » par police     : 36.23 €
```

3.4 Grille de tarif

```r
# Variables retenues par stepAIC dans chacun des deux modèles
vars_f <- attr(terms(mod_freq_opt), "term.labels")
vars_c <- attr(terms(mod_cout_opt), "term.labels")
cat("Variables du GLM fréquence :", paste(vars_f, collapse = ", "), "\n")
```

```
Variables du GLM fréquence : CLA3, VIT3, SEX, USAGE, K8000, RM, PERMIS, ACV
```

```r
cat("Variables du GLM coût      :", paste(vars_c, collapse = ", "), "\n")
```

```
Variables du GLM coût      : VIT3, STATUT, RM
```

```r
# Profil de base : modalités de référence et valeurs médianes
base <- list(CSP3 = "CAT1", CLA3 = "Inter", VIT3 = "VitMoy", CAR3 = "Luxe",
             SEX = "M", STATUT = "A", USAGE = "2", K8000 = "N", ENE = "ES",
             GARAGE = "3", RM = median(df$RM), AGECOND = median(df$AGECOND),
             PERMIS = median(df$PERMIS), ACV = median(df$ACV))

# La grille croise les variables qualitatives retenues les plus structurantes
# (classe SRA, vitesse, sexe) ; les autres restent au profil de base.
axes <- intersect(c("CLA3", "VIT3", "SEX"), union(vars_f, vars_c))
grille <- expand.grid(lapply(setNames(axes, axes), function(v) levels(df_freq[[v]])),
                      stringsAsFactors = FALSE)
for (v in setdiff(names(base), axes)) grille[[v]] <- base[[v]]

prep <- function(g, ref) {
  for (v in c("CSP3","CLA3","VIT3","CAR3","SEX","STATUT","USAGE","K8000","ENE","GARAGE"))
    g[[v]] <- factor(g[[v]], levels = levels(ref[[v]]))
  g
}
grille$freq_pred  <- predict(mod_freq_opt, newdata = prep(grille, df_freq), type = "response")
grille$cout_pred  <- predict(mod_cout_opt, newdata = prep(grille, train_c), type = "response")
grille$prime_pure <- grille$freq_pred * grille$cout_pred
grille$prime_totale <- grille$prime_pure + surprime_graves

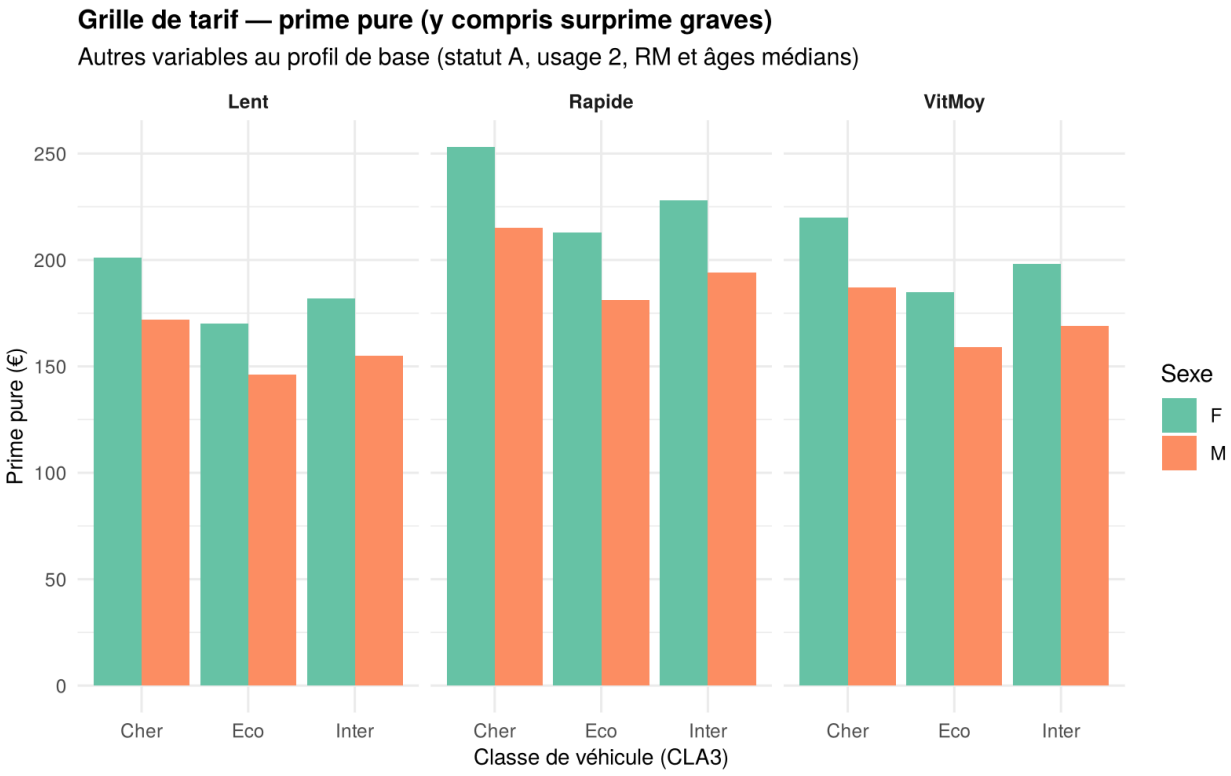
grille_aff <- grille[, c(axes, "freq_pred", "cout_pred", "prime_pure", "prime_totale")] |>
  mutate(freq_pred    = round(freq_pred * 100, 2),
         cout_pred    = round(cout_pred, 0),
         prime_pure   = round(prime_pure, 0),
         prime_totale = round(prime_totale, 0)) |>
  arrange(desc(prime_totale))

grille_aff |>
  kbl_out(caption = "Grille de tarif - prime pure par profil (€)",
          col.names = c(axes, "Fréq. (%)", "Coût moy. (€)",
                        "Prime pure attrit. (€)", "Prime pure + graves (€)"))
```

```r
ggplot(grille_aff, aes(x = CLA3, y = prime_totale, fill = SEX)) +
  geom_col(position = "dodge") +
  facet_wrap(~ VIT3, ncol = 3) +
  labs(
    title    = "Grille de tarif - prime pure (y compris surprime graves)",
    subtitle = "Autres variables au profil de base (statut A, usage 2, RM et âges médians)",
    x = "Classe de véhicule (CLA3)", y = "Prime pure (€)", fill = "Sexe"
  ) +
  scale_fill_brewer(palette = "Set2") +
  theme(strip.text = element_text(face = "bold"))
```

Table 12: Grille de tarif — prime pure par profil (€)

CLA3	VIT3	SEX	Fréq. (%)	Coût moy. (€)	Prime pure attrit. (€)	Prime pure + graves (€)
Cher	Rapide	F	12.70	1707	217	253
Inter	Rapide	F	11.22	1707	191	228
Cher	VitMoy	F	12.54	1463	183	220
Cher	Rapide	M	10.47	1707	179	215
Eco	Rapide	F	10.33	1707	176	213
Cher	Lent	F	10.63	1555	165	201
Inter	VitMoy	F	11.07	1463	162	198
Inter	Rapide	M	9.22	1707	157	194
Cher	VitMoy	M	10.33	1463	151	187
Eco	VitMoy	F	10.19	1463	149	185
Inter	Lent	F	9.36	1555	146	182
Eco	Rapide	M	8.48	1707	145	181
Cher	Lent	M	8.72	1555	136	172
Eco	Lent	F	8.61	1555	134	170
Inter	VitMoy	M	9.09	1463	133	169
Eco	VitMoy	M	8.36	1463	122	159
Inter	Lent	M	7.66	1555	119	155
Eco	Lent	M	7.04	1555	109	146



Lecture : prime pure = P(sinistre) × coût moyen conditionnel, augmentée de la surprime répartissant le coût des sinistres graves. Elle est ensuite majorée d'un **coefficient de chargement** (frais de gestion, marge, sécurité) pour obtenir la **prime commerciale**.

4 Synthèse

Étape	Méthode	Résultat
Séparation	Seuil Q99	1384 attritionnels / 14 graves
Adéquation coût	Gamma, log-normale, Weibull (MV, AIC/BIC, KS bootstrap)	Meilleur AIC : Log-normale ; KS rejette les lois testées ; GLM Gamma retenu comme hypothèse de travail
GLM fréquence	Binomial/logit + stepAIC	CLA3, VIT3, SEX, USAGE, K8000, RM, PERMIS, ACV — Gini test = 0.46
GLM coût	Gamma/log + stepAIC	VIT3, STATUT, RM
Prime pure	Fréquence × coût + surprime graves	Grille tarifaire par profil

4.1 Limites et pistes

- La base ne fournit pas d'exposition : la fréquence est modélisée comme la probabilité d'au moins un sinistre (binomiale) et non comme un nombre de sinistres (Poisson avec offset).
- Le seuil des sinistres graves (Q99) pourrait être affiné par une approche de valeurs extrêmes (mean excess plot, loi de Pareto généralisée).
- Variantes à tester : régression log-normale pour le coût, GLM Tweedie sur la charge totale, validation croisée k-fold.